การจำแนกการใช้ประโยชน์ที่ดินจากภาพถ่ายดาวเทียม Sentinel-2 ข้ามโดเมน

Cross-domain Land-Use Classification from Sentinel-2: Train in Europe, Test in Thailand

Group Assignment #2: Analytics on Complex Data

รายวิชา Data Mining ภาคต้น ปีการศึกษา 2569

มหาวิทยาลัยเกษตรศาสตร์

จัดทำโดย

ณัฏฐนนท์ รักพานิชมณี 6710503917

นพรุจ กาศอุดม 6710504000

ณัฐดนัย ผ่องเพ็ญศรี 6710503925

บทคัดย่อ

รายงานนี้ศึกษาว่าแบบจำลองจำแนกการใช้ประโยชน์ที่ดินที่ฝึกด้วยภาพ Sentinel-2 ของยุโรป (EuroSAT) ใช้กับประเทศไทยได้ดีเพียงใด ผลที่ลดลงมาจากอะไร และแก้ได้อย่างไร ข้อมูลไทยมาจาก 4 พื้นที่ศึกษาขนาด 30.72 × 30.72 km เป็นภาพหน้าแล้งปี 2021 ตัดเป็น patch 64 × 64 pixel ใช้ label จาก ESA WorldCover และ label ที่สมาชิกตรวจด้วยตา 199 patch

ResNet-18 ที่รับภาพ 12 band ได้ macro-F1 **0.992** ในยุโรป แต่เหลือ **0.831 ± 0.027** ในไทย (ภาพระดับ L1C) และเหลือ 0.396 เมื่อใช้ภาพระดับ L2A AdaBN ซึ่งไม่ใช้ label เพิ่มผลเป็น 0.915 และเป็น 0.946 เมื่อตัดคลาส grassland ที่แทบไม่มีในไทย 69% ของข้อผิดพลาดคือป่าที่ถูกทำนายเป็น grassland ซึ่งเป็นป่าที่แห้งในหน้าแล้ง และเมื่อวัดบนบล็อกทดสอบชุดเดียวกัน การ fine-tune ด้วย patch ไทยเพียง 10 patch ต่อคลาสเพิ่มผลจาก 0.847 (ไม่ปรับ) และ 0.912 (AdaBN + ตัด grassland) เป็น 0.969 สรุปได้ว่า domain shift ในงานนี้มาจากระดับการประมวลผลของภาพและลักษณะของพืชพรรณตามฤดูกาล

คำสำคัญ: land-use classification, Sentinel-2, domain shift, transfer learning, AdaBN, fine-tuning

บทคัดย่อ 2
1. บทนำ 3
2. ข้อมูลและความซับซ้อนของข้อมูล 3
3. การสำรวจข้อมูล (Complex Data Exploration) 4
4. การเตรียมข้อมูล (Complex Data Pre-processing) 6
5. เทคนิคการวิเคราะห์ (Analytics Technique) 7
6. ผลการทดลอง 8
7. การวิเคราะห์ข้อผิดพลาดและอภิปรายผล 11
8. การประยุกต์ใช้ 12
9. ข้อจำกัดและงานต่อ 13
10. สรุป 13
เอกสารอ้างอิง 14
ภาคผนวก: การแบ่งงานและโค้ด 14

1. บทนำ

แผนที่การใช้ประโยชน์ที่ดินใช้วางผังเมือง ติดตามการทำลายป่า และประเมินพื้นที่เพาะปลูก ภาพ Sentinel-2 ครอบคลุมทั่วโลกทุก 5 วันที่ความละเอียด 10 m แต่การฝึกแบบจำลองต้องใช้ข้อมูลที่มี label จำนวนมาก ซึ่งไทยยังไม่มีในรูปแบบที่พร้อมใช้ ทางเลือกคือฝึกด้วยชุดข้อมูลสาธารณะของภูมิภาคอื่น แต่ภาพจากสองภูมิภาคต่างกันทั้งภูมิอากาศ ฤดูกาล พืชพรรณ และวิธีประมวลผลภาพ ความต่างนี้เรียกว่า **domain shift** งานนี้ตอบคำถาม 3 ข้อ

1. แบบจำลองที่ฝึกด้วยภาพของยุโรปจำแนกพื้นที่ศึกษาของไทยได้ดีเพียงใด
2. ผลที่ลดลงมาจากความแตกต่างด้านใดของข้อมูล
3. วิธีปรับแบบจำลองแบบใดช่วยได้ และต้องใช้ label ของไทยมากน้อยเพียงใด

ขอบเขต: จำแนก 5 คลาส (forest, crop, grassland, built-up, water) ฝึกด้วย EuroSAT เท่านั้น ประเมินฝั่งไทย 4 คลาส (ไม่รวม grassland ดูหัวข้อ 4.3) และผลสะท้อนพื้นที่ศึกษา ไม่ใช่ทั้งประเทศ

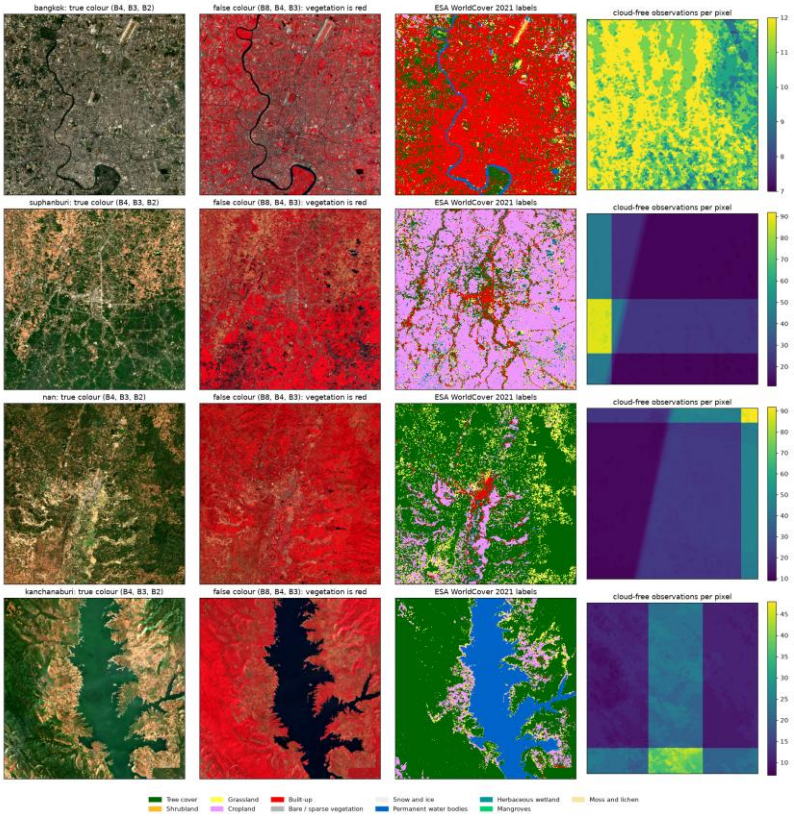
2. ข้อมูลและความซับซ้อนของข้อมูล

ชนิดของข้อมูล: ข้อมูลเป็นภาพถ่ายดาวเทียมหลายช่วงคลื่น (multispectral image) ไม่ใช่ข้อมูลตาราง หน่วยที่วิเคราะห์คือ patch ขนาด 64 × 64 pixel (640 × 640 m) แต่ละ pixel มี 12 ค่าจาก 12 band เป็นค่าการสะท้อนแสงแบบต่อเนื่อง (reflectance × 10,000) และทุก pixel มีพิกัดบนแผนที่ ส่วน label เป็นข้อมูลหมวดหมู่ 5 คลาส โจทย์จึงเป็น image classification ที่ต้องใช้ทั้งค่าในแต่ละ band และรูปแบบเชิงพื้นที่ภายใน patch

ตารางที่ 1 แหล่งข้อมูล

แหล่งข้อมูล	บทบาท	ลักษณะ	Label
EuroSAT (Helber et al., 2019)	ชุดฝึก	27,000 patch 64 × 64 pixel จาก 34 ประเทศในยุโรป, Sentinel-2 L1C, 13 band	สะอาด, 1 label ต่อ patch, 10 คลาส
Sentinel-2 ของไทย (Google Earth Engine)	ภาพทดสอบ	4 พื้นที่ศึกษา, ม.ค.–ก.พ. 2021, ระดับ L1C และ L2A	ไม่มี
ESA WorldCover 10 m v200 (2021)	label ทดสอบ	แผนที่สิ่งปกคลุมดินที่สร้างจากแบบจำลอง	1 label ต่อ pixel, 11 คลาส, มีความคลาดเคลื่อน
Label ที่ตรวจด้วยตา	label ทดสอบชุดสะอาด	199 patch, ผลโหวตของสมาชิก 3 คน	1 label ต่อ patch

พื้นที่ศึกษาแต่ละแห่งเป็นสี่เหลี่ยม 30.72 × 30.72 km (3,072 × 3,072 pixel) วางรอบจุดศูนย์กลาง ไม่ได้ครอบคลุมทั้งจังหวัด และเลือกให้แต่ละแห่งเด่นคนละคลาส ได้แก่ **กรุงเทพฯ** (built-up 67%), **สุพรรณบุรี** (นาข้าวชลประทาน, cropland 68%), **น่าน** (ป่าบนภูเขา, tree cover 73%) และ**เขื่อนศรีนครินทร์ กาญจนบุรี** (tree cover 63%, water 24%) (รูปที่ 1)



รูปที่ 1 พื้นที่ศึกษา 4 แห่ง: ภาพสีจริง, false colour (พืชเป็นสีแดง), label จาก WorldCover และจำนวนภาพไร้เมฆต่อ pixel

ความซับซ้อนของข้อมูล ที่ต้องจัดการในขั้นเตรียมข้อมูล (หัวข้อ 4):

- **หลายแหล่งและหลายความละเอียด:** ภาพกับ label มาจากคนละแหล่ง band มี pixel 10, 20 และ 60 m ต้องจัดให้อยู่บน grid เดียวกัน
- **มิติสูง:** 1 patch มี 12–13 band × 4,096 pixel ประมาณ 50,000 ค่า
- **เมฆ:** ภาพไทยมีเมฆบังบางส่วนในแต่ละวัน
- **label ไม่ตรงกัน:** 10 คลาสของ EuroSAT กับ 11 คลาสของ WorldCover, label ต่อภาพกับ label ต่อ pixel และ WorldCover มีความคลาดเคลื่อน (ความถูกต้องโดยรวมประมาณ 75%)
- **ไม่สมดุลและ domain shift:** ทั้งสองฝั่งไม่สมดุลในทิศทางตรงข้ามกัน และต่างกันทั้งภูมิภาค ฤดูกาล และระดับการประมวลผลของภาพ

3. การสำรวจข้อมูล (Complex Data Exploration)

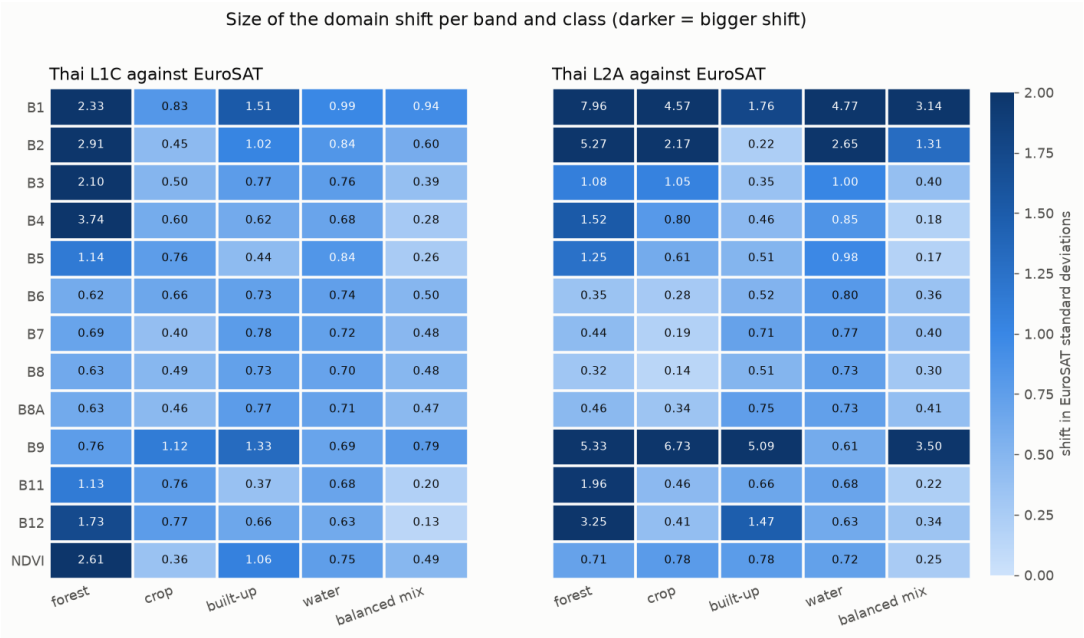
เปรียบเทียบ pixel ของ EuroSAT (ชุดฝึก) กับ patch ไทยที่ผ่านเกณฑ์ ทั้งระดับ L1C และ L2A โดยสุ่ม 100,000 pixel ต่อคลาสต่อแหล่งด้วย seed เดียวกันในทุกการวิเคราะห์

ตารางที่ 2 จำนวน patch ต่อคลาส: EuroSAT (train / validation / test) และ patch ไทยที่ผ่านเกณฑ์ แยกตามพื้นที่ศึกษา

คลาส	EuroSAT	กรุงเทพฯ	สุพรรณบุรี	น่าน	กาญจนบุรี	ไทย รวม
forest	2,100 / 450 / 450	5	0	683	1,088	1,776
crop	3,850 / 825 / 825	0	521	13	1	535
grassland	3,500 / 750 / 750	0	0	0	0	0
built-up	5,600 / 1,200 / 1,200	280	1	0	0	281
water	3,850 / 825 / 825	0	0	0	431	431

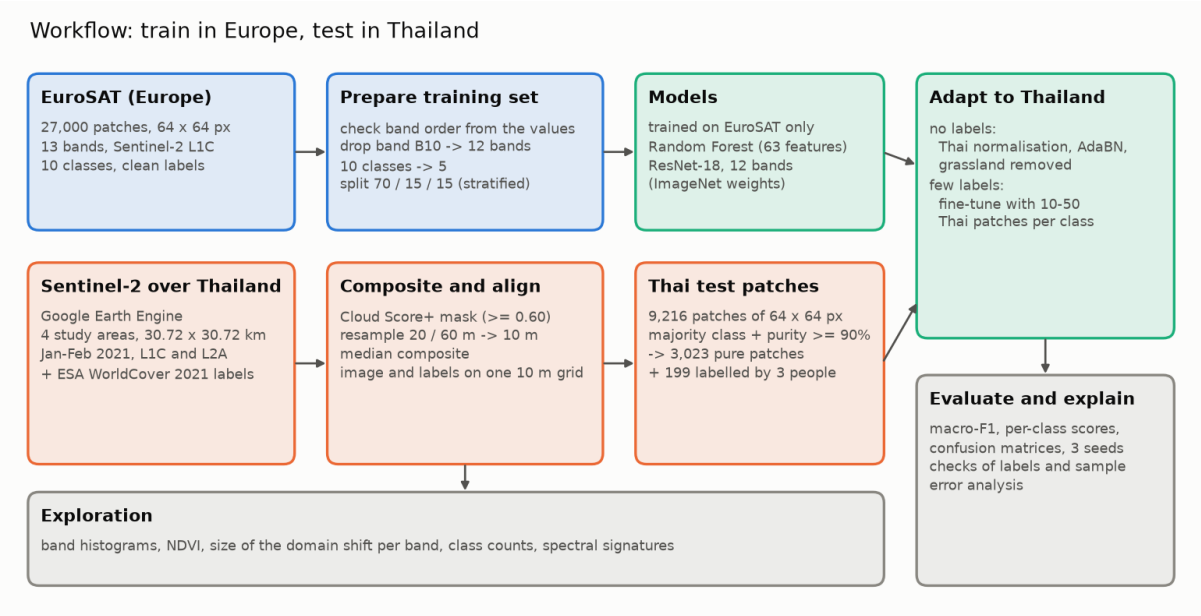
- **ไม่สมดุลในทิศทางตรงข้ามกัน:** EuroSAT มี built-up มากกว่า forest 2.7 เท่า แต่ไทยมี forest มากกว่า built-up 6.3 เท่า และแต่ละคลาสของไทยมาจากพื้นที่เดียวเกือบทั้งหมด
- **ป่าไทยเขียวน้อยกว่าป่ายุโรปมาก:** ค่ามัธยฐานของ NDVI ของ forest คือ 0.737 ใน EuroSAT แต่ 0.525 ในไทย L1C กฎจำแนกด้วย NDVI ที่ตั้งจาก EuroSAT มี recall ของ forest 0.97 ในยุโรป แต่เหลือ 0.45 ในไทย
- **ภาพ L2A ต่างจาก EuroSAT มากกว่า L1C มาก:** วัดด้วย Wasserstein distance ในหน่วย SD ของ EuroSAT เมื่อรวมทุกคลาส ภาพ L1C ต่างไม่ถึง 1 SD ในทุก band แต่ L2A ต่าง 3.50 SD ใน band B9 และ 3.14 SD ใน band B1 เพราะ EuroSAT เป็นระดับ L1C ส่วน L2A ผ่านการแก้ค่าบรรยากาศ (รูปที่ 2)

ข้อค้นพบเหล่านี้นำไปสู่การตัดสินใจ 2 ข้อ คือใช้ภาพ **L1C เป็นชุดทดสอบหลัก** (L2A ใช้เปรียบเทียบ) และ**ประเมินด้วย macro-F1 และผลรายคลาส** แทน accuracy อย่างเดียว



รูปที่ 2 ขนาดของ domain shift ต่อ band และคลาส (หน่วย: จำนวน SD ของ EuroSAT; สีเข้ม = ต่างมาก)

4. การเตรียมข้อมูล (Complex Data Pre-processing)



รูปที่ 3 ขั้นตอนการทำงานทั้งหมด

4.1 ภาพไทย

1. **ช่วงเวลา** 1 ม.ค. – 1 มี.ค. 2021: หน้าแล้งที่เมฆน้อย และปีเดียวกับ WorldCover v200
2. **Cloud masking** ด้วย Cloud Score+ ซึ่งให้คะแนนความใสของทุก pixel ในทุกภาพ เก็บเฉพาะ pixel ที่คะแนน ≥ 0.60
3. **Resample** band 20 m และ 60 m เป็น 10 m ด้วย bilinear (label ใช้ nearest neighbour เพราะเป็นรหัสคลาส)
4. **Median composite** ใช้ค่ามัธยฐานของวันที่ไม่มีเมฆในแต่ละ pixel ทนต่อเมฆบางหรือหมอกควันที่หลุดมา ทุก pixel มีภาพไร้เมฆอย่างน้อย 7 ครั้ง
5. **จัด grid ให้ตรงกัน** ภาพและ label อยู่บน grid 10 m เดียวกัน (UTM 47N) pixel ตำแหน่งเดียวกันจึงเป็นจุดเดียวกันบนพื้นดิน

4.2 EuroSAT และการจับคู่คลาส

- **ตรวจลำดับ band จากค่าจริง** เพราะไฟล์ไม่มีชื่อ band: ช่องที่ 9 มีค่าเฉลี่ยเพียง 12 ตรงกับ band B10 (cirrus) และช่องที่ 12 สัมพันธ์กับ band B7 ที่ r = 0.996 ตรงกับ band B8A
- **ตัด band B10 เหลือ 12 band** ที่ทั้งสองฝั่งมีร่วมกัน (ภาพ L2A ไม่มี band B10)
- **แบ่งข้อมูล** 70 / 15 / 15 แบบ stratified (seed 42) ได้ 18,900 / 4,050 / 4,050 patch

ตารางที่ 3 การจับคู่คลาสเข้ากับ 5 คลาสเป้าหมาย

คลาสเป้าหมาย	จาก EuroSAT	จาก WorldCover (รหัส)
forest	Forest	Tree cover (10)
crop	AnnualCrop, PermanentCrop	Cropland (40)
grassland	Pasture, HerbaceousVegetation	Grassland (30)
built-up	Residential, Industrial, Highway	Built-up (50)
water	River, SeaLake	Permanent water bodies (80)

4.3 ตัด patch, purity และปัญหาที่พบ

แต่ละพื้นที่ถูกตัดเป็นตาราง 48 × 48 ช่อง ช่องละ 64 × 64 pixel รวม 9,216 patch ทุก patch ได้ label เป็นคลาสที่ครอบคลุมพื้นที่มากที่สุด (majority vote) และเก็บเฉพาะ patch ที่คลาสนั้นครอบคลุม ≥ 90% (**purity**) เหลือ 3,023 patch ซึ่งลดทั้ง mixed pixel และ label ที่คลาดเคลื่อน

รอบแรกใช้ 3 พื้นที่ และพบว่า **grassland และ water ไม่มี patch ผ่านเกณฑ์เลย** จึงคำนวณสัดส่วนของทั้งสองคลาสในทุกช่องขนาดเท่า patch ทั่วไทย (ประมาณ 1.07 ล้านช่อง) พบ water 5,574 ช่อง จึงเพิ่มพื้นที่เขื่อนศรีนครินทร์ ได้ water 431 patch แต่ grassland มีเพียง 399 ช่อง (0.04% ของพื้นที่) จึงไม่ประเมิน grassland ฝั่งไทย แต่ยังรายงานว่าแบบจำลองทำนาย grassland ผิดบ่อยเพียงใด

4.4 ชุดทดสอบที่ตรวจด้วยตา

สมาชิก 3 คนจำแนก 200 patch ด้วยตา (คลาสละ 50) ผ่านเครื่องมือที่ซ่อนชื่อพื้นที่และ label ของ WorldCover ความสอดคล้องสูงมาก (**Fleiss' kappa = 0.962**) ได้ label จากการโหวต 199 patch ใช้ตรวจว่า label ของ WorldCover เชื่อถือได้เพียงใด

5. เทคนิคการวิเคราะห์ (Analytics Technique)

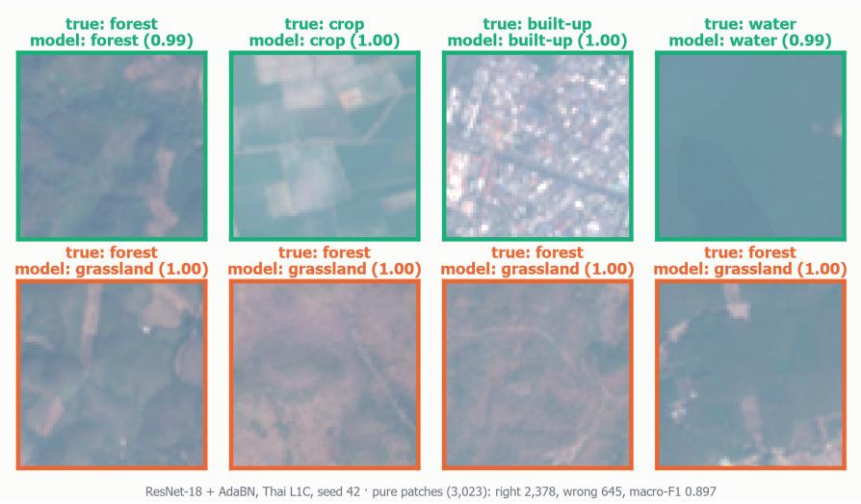
- **Random Forest (baseline):** 300 ต้น ใช้ feature 63 ตัวต่อ patch คือ ค่าเฉลี่ย, SD และ percentile 10/50/90 ของ 12 band กับค่าเฉลี่ย NDVI, NDWI, NDBI
- **ResNet-18:** convolutional neural network ที่มี residual connection (He et al., 2016) เริ่มจาก weight ที่ฝึกบน ImageNet (transfer learning) ปรับชั้นแรกให้รับ 12 channel ฝึกด้วย AdamW (learning rate 1e-3) และ cross-entropy ถ่วงน้ำหนักตามคลาส augmentation เฉพาะการพลิกและหมุนภาพ (ไม่ปรับสีเพื่อไม่ให้บดบัง domain shift) เก็บ epoch ที่ macro-F1 บน validation สูงสุด และฝึกซ้ำ 3 seed
- **Thai normalisation:** normalise ภาพไทยด้วยค่าเฉลี่ยและ SD ของแต่ละ band ที่คำนวณจากภาพไทยเอง แทนค่าของ EuroSAT เป็นวิธีปรับความต่างของค่าแสงที่ง่ายที่สุด แต่ปรับได้เฉพาะข้อมูลขาเข้า ไม่ได้ปรับสถิติภายในแบบจำลอง
- **AdaBN** (Li et al., 2016): คำนวณค่าเฉลี่ยและความแปรปรวนในชั้น BatchNorm ใหม่จากภาพไทยที่ไม่มี label โดยไม่เปลี่ยน weight เปรียบเหมือนตั้งศูนย์ของเครื่องวัดใหม่ ทั้งสองวิธีใช้สถิติจาก patch ไทย 6,193 patch ที่ไม่ผ่านเกณฑ์ purity จึงไม่แตะชุดทดสอบ
- **ตัด grassland:** ตั้งความน่าจะเป็นของ grassland เป็นศูนย์ ใช้ความรู้ว่า grassland แทบไม่มีในไทย ไม่ได้ใช้ label ทดสอบ

- **Fine-tuning:** ฝึก ResNet-18 ต่อด้วย patch ไทยที่มี label 10, 25 หรือ 50 patch ต่อคลาส (สุ่ม 3 รอบ) เพื่อกันข้อมูลรั่วจึง**แบ่งแต่ละพื้นที่เป็นบล็อก 5.1 km** ครึ่งหนึ่งใช้ฝึก อีกครึ่งใช้ทดสอบ patch ฝึกห่างจาก patch ทดสอบอย่างน้อย 640 m และไม่ใช้ 199 patch ที่ตรวจด้วยตา

ResNet, transfer learning, AdaBN และ fine-tuning เป็นเทคนิคที่อยู่นอกเนื้อหาในชั้นเรียน ส่วน Random Forest ต่อยอดจาก decision tree ที่เรียนมา

Demo

Notebook `notebooks/demo_predict.ipynb` (และสคริปต์ `src/demo_predict.py` ที่ทำงานเหมือนกัน) สาธิตขั้นตอนครบสำหรับแบบจำลองหนึ่งตัว คือ (1) โหลด ResNet-18 ที่ฝึกบน EuroSAT (seed 42) (2) ทำ AdaBN ด้วย patch ไทย 6,193 patch ที่ไม่ pure โดยไม่ใช้ label (3) ทำนายทุก patch แล้วคิดคะแนนบน 3,023 patch ที่ pure และ (4) แสดงภาพ patch ที่ทำนายถูกคลาสละหนึ่งภาพ กับป่าที่ถูกทำนายเป็น grassland (รูปที่ 4) ผลคือทำนายถูก 2,378 patch ผิด 645 patch และ macro-F1 0.897 ตรงกับผล AdaBN ของ seed 42 (ค่าเฉลี่ย 3 seed ในตารางที่ 4 คือ 0.915)
ในวิดีโอใช้โหมดอ่านผลทำนายที่บันทึกไว้จาก `src/predict.py` ตัวเลขจึงตรงกับรายงาน



รูปที่ 4 ผลของ demo: แถวบนคือ patch ที่ทำนายถูกคลาสละหนึ่งภาพ แถวล่างคือป่าที่ถูกทำนายเป็น grassland (ResNet-18 + AdaBN, ไทย L1C, seed 42)

6. ผลการทดลอง

การประเมิน: ชุดทดสอบหลักคือ patch ไทย 3,023 patch กับ label ของ WorldCover และชุดสะอาด 199 patch กับ label ของคน ตัวชี้วัดหลักคือ **macro-F1** (ให้น้ำหนักทุกคลาสเท่ากัน) คู่กับ accuracy และผลรายคลาส ฝั่งไทยวัด 4 คลาส โดยการทำนาย grassland นับเป็นคำตอบที่ผิด

6.1 ผลรวม

ตารางที่ 4 macro-F1 และ accuracy (ResNet-18: ค่าเฉลี่ย ± SD ของ 3 seed; Random Forest: seed 42)

แบบจำลอง / ข้อมูลทดสอบ / การปรับ	Accuracy	Macro-F1	Macro-F1 (ชุดสะอาด)
ResNet-18 / EuroSAT test	0.992 ± 0.001	0.992 ± 0.001	–
ResNet-18 / ไทย L1C / ไม่ปรับ	0.675 ± 0.036	0.831 ± 0.027	0.809 ± 0.024
ResNet-18 / ไทย L1C / Thai normalisation	0.742 ± 0.030	0.823 ± 0.021	0.813 ± 0.015
ResNet-18 / ไทย L1C / AdaBN	0.818 ± 0.030	0.915 ± 0.015	0.885 ± 0.012
ResNet-18 / ไทย L1C / AdaBN + ตัด grassland	**0.956 ± 0.018**	**0.946 ± 0.018**	**0.941 ± 0.012**
ResNet-18 / ไทย L2A / ไม่ปรับ	0.281 ± 0.097	0.396 ± 0.045	0.394 ± 0.022
Random Forest / EuroSAT test	0.944	0.949	–
Random Forest / ไทย L1C / ไม่ปรับ	0.605	0.707	0.782

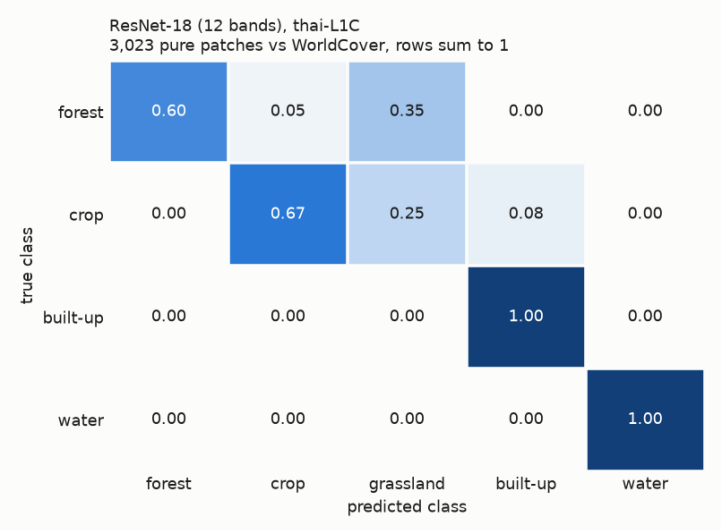
- **มี domain shift จริง:** 0.992 ในยุโรป เหลือ 0.831 ในพื้นที่ศึกษาของไทย
- **ระดับการประมวลผลของภาพสำคัญมาก:** ภาพ L2A ได้เพียง 0.396 เพราะแบบจำลองทำนาย grassland ถึง 76% ของ patch (seed 42) สอดคล้องกับหัวข้อ 3
- **AdaBN ช่วยได้มากโดยไม่ใช้ label** (0.915) และเมื่อรวมกับการตัด grassland ได้ 0.946 ส่วน Thai normalisation ไม่ช่วย
- **ResNet-18 ดีกว่า Random Forest** ทั้งในยุโรปและในไทย (0.831 เทียบกับ 0.707)

6.2 ผลรายคลาส

ตารางที่ 5 F1 รายคลาสของ ResNet-18 (seed 42)

คลาส	EuroSAT test	ไทย L1C	ไทย L1C + AdaBN	ไทย L2A
forest	0.993	0.749	0.824	0.184
crop	0.988	0.725	0.856	0.163
built-up	0.995	0.927	0.958	0.035
water	0.996	0.996	0.950	0.995

ในไทย L1C, water และ built-up ทำได้ดีมาก (recall 1.00 ทั้งคู่) ปัญหาอยู่ที่ forest ซึ่ง precision 0.999 แต่ recall เพียง 0.598 คือเมื่อตอบว่าเป็นป่าจะถูกเกือบทุกครั้ง แต่ป่า 35% ถูกตอบเป็น grassland (รูปที่ 5)



รูปที่ 5 Confusion matrix ของ ResNet-18 บนไทย L1C แบบไม่ปรับ (แต่ละแถวรวมเป็น 1)

6.3 ความน่าเชื่อถือของ label และชุดทดสอบ

- **label ของ WorldCover เชื่อถือได้สำหรับ patch ที่ pure:** ตรงกับการโหวตของคน 98.0% (ช่วงความเชื่อมั่น 95%: 94.9–99.2%) การเปลี่ยน label เปลี่ยนคะแนนไม่เกิน 0.021 และชุดทดสอบทั้งสองเรียงลำดับวิธีเหมือนกัน (Spearman 0.982)
- **accuracy ของสองชุดเทียบกันไม่ได้** เพราะสัดส่วนคลาสต่างกัน (ชุดใหญ่เป็น forest 59%) และชุด 199 patch แม่นประมาณ ±0.04 macro-F1 ตัวเลขหลักจึงใช้ชุด 3,023 patch

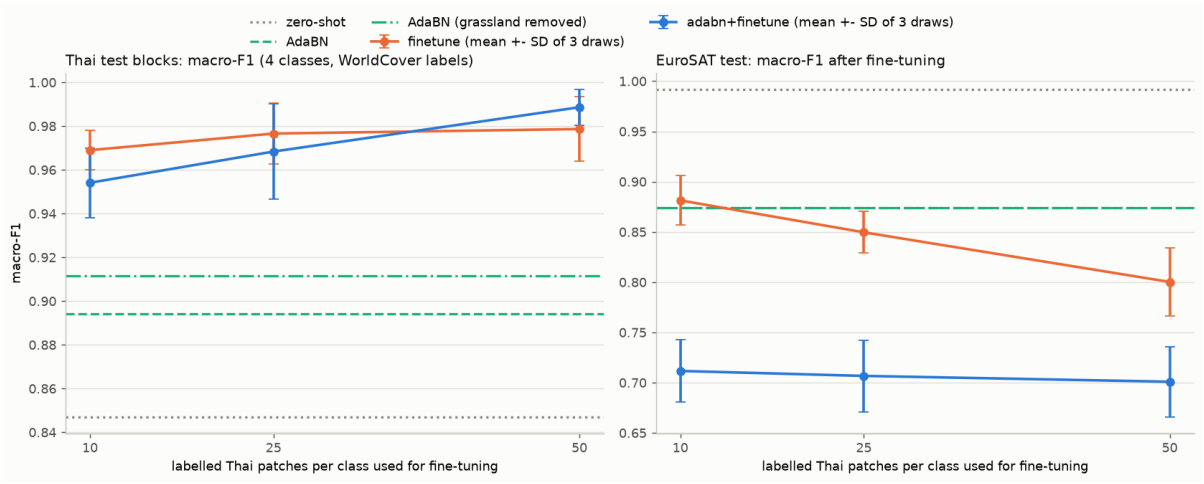
6.4 Fine-tuning ด้วย patch ไทยจำนวนน้อย

ตารางที่ 6 ผลบนบล็อกทดสอบ (1,540 patch กับ WorldCover และ 106 patch ที่ตรวจด้วยตา) ค่าเฉลี่ย ± SD ของ 3 รอบสุ่ม

วิธี	patch ไทยต่อคลาส	Macro-F1 (WorldCover)	Macro-F1 (ตรวจด้วยตา)	EuroSAT test
ไม่ปรับ (zero-shot)	0	0.847	0.839	0.992
AdaBN + ตัด grassland	0	0.912	0.932	0.874
fine-tune	**10**	**0.969 ± 0.009**	**0.968 ± 0.006**	0.881 ± 0.024
fine-tune	25	0.977 ± 0.014	0.987 ± 0.003	0.850 ± 0.021
fine-tune	50	0.979 ± 0.015	0.990 ± 0.010	0.800 ± 0.034

- **patch ไทยเพียง 10 patch ต่อคลาสให้ผลดีกว่าทุกวิธีที่ไม่ใช้ label** บนบล็อกทดสอบชุดเดียวกัน: ไม่ปรับ 0.847, AdaBN + ตัด grassland 0.912, fine-tune 0.969 และ recall ของ forest เพิ่มจาก 0.58 เป็นประมาณ 0.95
- **เพิ่มเกิน 10 patch ได้ประโยชน์น้อย** และแบบจำลองลืมยุโรปไปบางส่วน (EuroSAT ลดเหลือ 0.80–0.88) การทำ AdaBN ก่อน fine-tune ไม่ช่วยเพิ่ม

หมายเหตุ: ชุดทดสอบของตารางนี้คือครึ่งหนึ่งของพื้นที่ และแบบจำลองฐานฝึกใหม่ด้วยโค้ดและ seed เดียวกัน จึงเทียบได้ภายในตารางนี้เท่านั้น



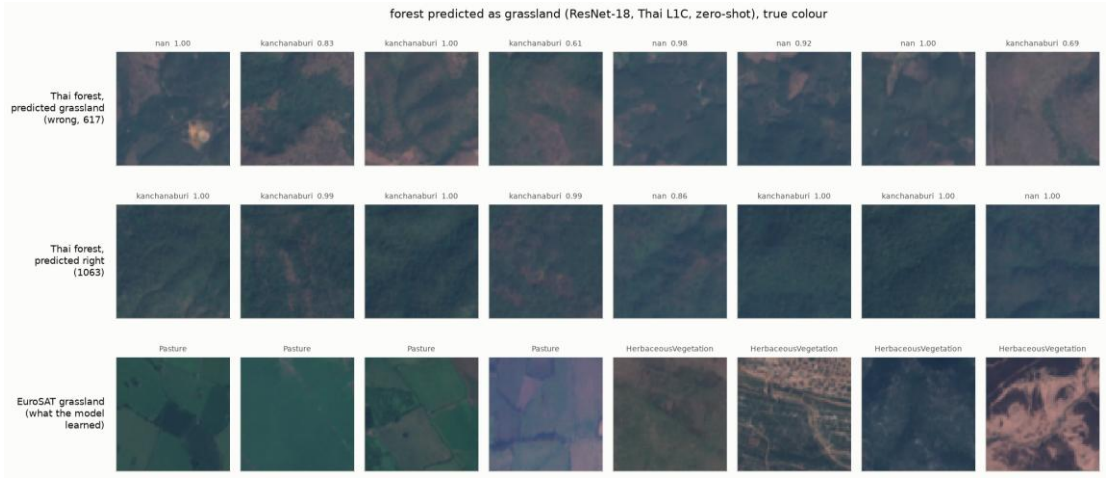
รูปที่ 6 macro-F1 ของไทยเทียบกับจำนวน patch ที่ใช้ fine-tune (ซ้าย) และ macro-F1 บน EuroSAT หลัง fine-tune (ขวา)

7. การวิเคราะห์ข้อผิดพลาดและอภิปรายผล

ตารางที่ 7 ข้อผิดพลาดของ ResNet-18 บนไทย L1C (seed 42) ผิด 891 จาก 3,023 patch

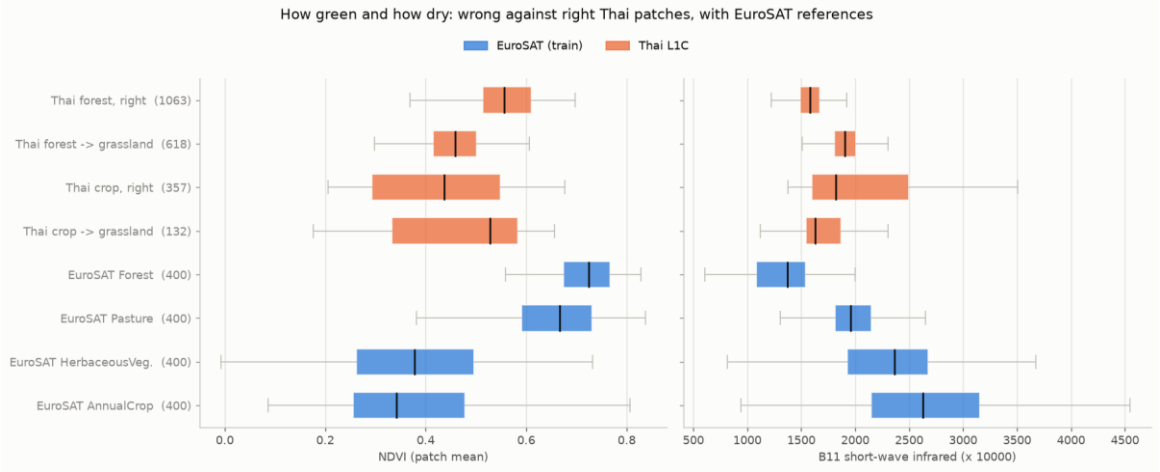
คลาสจริง → ทำนาย	ไม่ปรับ	สัดส่วน	AdaBN
forest → grassland	618	69%	484
crop → grassland	132	15%	59
forest → crop	93	10%	10
crop → built-up	43	5%	14

- **built-up และ water ไม่ผิดเลย** ปัญหาทั้งหมดอยู่ที่พืชพรรณ
- **ผิดเป็นระบบและมั่นใจ:** 743 patch ผิดในทั้ง 3 seed และ 44% ของคำตอบที่ผิดมีความมั่นใจเกิน 0.95
- **เป็นความผิดของแบบจำลอง ไม่ใช่ของ label:** ใน 45 patch ของชุดสะอาดที่แบบจำลองไม่ตรงกับ WorldCover ผู้จำแนกเห็นด้วยกับ WorldCover 41 ครั้ง และกับแบบจำลองเพียง 1 ครั้ง



รูปที่ 7 ป่าไทยที่ถูกทำนายเป็น grassland (บน), ป่าไทยที่ทำนายถูก (กลาง) และ grassland ของ EuroSAT ที่แบบจำลองเรียนมา (ล่าง) สุ่มด้วย seed 42

ป่าที่ผิดคือป่าที่แห้งกว่า patch ป่าที่ถูกทำนายเป็น grassland มีแสงสีแดงและ short-wave infrared (SWIR) สูงกว่า และ NDVI ต่ำกว่าป่าที่ทำนายถูก SWIR เพียงตัวเดียวแยกสองกลุ่มได้ดีมาก (AUC 0.95–0.97) และค่าของป่ากลุ่มนี้ใกล้กับ Pasture ของยุโรปมากกว่า Forest (รูปที่ 8)
ในภาพเห็นเรือนยอดเป็นจุดน้ำตาลปนเขียว คำอธิบายที่น่าจะเป็น (ยังไม่ได้พิสูจน์ด้วยภาพฤดูอื่น) คือป่าบางส่วนผลัดใบหรือแห้งในหน้าแล้ง ซึ่งแบบจำลองไม่เคยเห็นใน EuroSAT ผลของ fine-tuning สนับสนุนคำอธิบายนี้



รูปที่ 8 NDVI และ SWIR (B11) ของ patch ไทยที่ทำนายถูกและผิด เทียบกับคลาสอ้างอิงของ EuroSAT

นาข้าวที่ผิดคือนาที่เขียว ไม่ใช่นาที่เป็นดินเปล่าอย่างที่คาดไว้ (NDVI 0.53 เทียบกับ 0.44 ของนาที่ทำนายถูก) แปลงข้าวเขียวสม่ำเสมอดูคล้าย Pasture ของยุโรป
ส่วนนาที่มีถนนหรือคลองตัดผ่านถูกทำนายเป็น built-up น่าจะเพราะคลาส built-up ของ EuroSAT รวม Highway ที่มีถนนเส้นตรงตัดผ่านพื้นที่เกษตร

อภิปราย: domain shift ในงานนี้มี 2 ส่วนหลัก คือ**ระดับการประมวลผลของภาพ** ซึ่งแก้ได้ด้วยการใช้ภาพระดับเดียวกับชุดฝึก และ**ลักษณะของพืชพรรณในฤดูของภาพ** ซึ่งเป็นสาเหตุของข้อผิดพลาดที่เหลือเกือบทั้งหมด AdaBN แก้ความต่างด้านสถิติได้ แต่สอนสิ่งที่แบบจำลองไม่เคยเห็นไม่ได้ ส่วน fine-tuning ด้วยตัวอย่างไม่กี่สิบตัวแก้ได้ ข้อเสนอเชิงปฏิบัติคือ การทำ label ในพื้นที่เป้าหมายเพียงไม่กี่สิบตัวอย่างต่อคลาสคุ้มค่ากว่าการปรับแบบจำลองโดยไม่ใช้ label

8. การประยุกต์ใช้

- ทำแผนที่การใช้ประโยชน์ที่ดินในพื้นที่ที่ไม่มีข้อมูล label
  โดยใช้แบบจำลองจากชุดข้อมูลสาธารณะแล้วปรับด้วยตัวอย่างในพื้นที่จำนวนน้อย
- ติดตามการเปลี่ยนแปลงของป่าและการขยายตัวของเมืองจากภาพ Sentinel-2 ที่ได้ใหม่ทุก 5 วัน
- ตรวจสอบคุณภาพของแผนที่สำเร็จรูป เช่น WorldCover และวางแผนว่าควรเก็บตัวอย่าง label ในพื้นที่ใหม่เท่าใด

9. ข้อจำกัดและงานต่อ

- แต่ละคลาสของไทยมาจากพื้นที่ศึกษาเดียวเกือบทั้งหมด ผลจึงสะท้อนพื้นที่ศึกษา ไม่ใช่ทั้งประเทศ
- ใช้ภาพหน้าแล้งช่วงเดียว และทดสอบเฉพาะ patch ที่ pure ซึ่งเป็นกรณีที่ง่าย
- fine-tuning ฝึกและทดสอบในพื้นที่ศึกษาเดียวกัน พื้นที่ใหม่น่าจะได้ผลต่ำกว่านี้
- **งานต่อ:** ใช้ภาพหลายฤดู, ทดสอบกับพื้นที่ใหม่ที่ไม่ได้ใช้ฝึก, เพิ่ม patch ที่มีหลายคลาส และกำหนดคลาสให้เหมาะกับไทย เช่น แยกนาข้าว สวน และป่าผลัดใบ

10. สรุป

คำถามที่ 1: ResNet-18 ที่ฝึกด้วยภาพของยุโรปได้ macro-F1 0.831 ± 0.027 ในพื้นที่ศึกษาของไทย ลดจาก 0.992 ในยุโรป built-up และ water ยังทำได้ดีมาก แต่ forest และ crop ผิดมาก

คำถามที่ 2: ผลที่ลดลงมาจากระดับการประมวลผลของภาพที่ไม่ตรงกัน (L2A ได้เพียง 0.396) และจากพืชพรรณในหน้าแล้ง ป่าที่แห้งถูกทำนายเป็น grassland คิดเป็น 69% ของข้อผิดพลาด ส่วน label ของ WorldCover ไม่ใช่สาเหตุ เพราะตรงกับการตรวจด้วยตา 98%

คำถามที่ 3: ถ้าไม่มี label ของไทย AdaBN ร่วมกับการตัด grassland ดีที่สุด (0.946 บนชุดทดสอบ 3,023 patch) ถ้ามี label เพียง 10 patch ต่อคลาส fine-tuning ดีกว่าชัดเจน เมื่อวัดบนบล็อกทดสอบชุดเดียวกันได้ 0.969 เทียบกับ 0.912 ของ AdaBN + ตัด grassland และแก้ปัญหาป่าแห้งได้เกือบทั้งหมด (ตัวเลข 0.946 กับ 0.969 วัดบนชุดทดสอบต่างกัน จึงไม่ควรนำมาเทียบกันโดยตรง)

เอกสารอ้างอิง

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.

Drusch, M., Del Bello, U., Carlier, S., et al. (2012). Sentinel-2: ESA's optical high-resolution mission for GMES operational services. Remote Sensing of Environment, 120, 25–36.

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. Remote Sensing of Environment, 202, 18–27.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of CVPR (pp. 770–778).

Helber, P., Bischke, B., Dengel, A., & Borth, D. (2019). EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 12(7), 2217–2226.

Li, Y., Wang, N., Shi, J., Liu, J., & Hou, X. (2016). Revisiting batch normalization for practical domain adaptation. arXiv:1603.04779.

Pasquarella, V. J., Brown, C. F., Czerwinski, W., & Rucklidge, W. J. (2023). Comprehensive quality assessment of optical satellite imagery using weakly supervised video learning. In CVPR Workshops (pp. 2125–2135).

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Wightman, R. (2019). PyTorch Image Models (timm). GitHub repository. https://github.com/huggingface/pytorch-image-models

Zanaga, D., Van De Kerchove, R., Daems, D., et al. (2022). ESA WorldCover 10 m 2021 v200. Zenodo. https://doi.org/10.5281/zenodo.7254221

ภาคผนวก: การแบ่งงานและโค้ด

โค้ดและผลลัพธ์ทั้งหมดอยู่ใน GitHub repository:

https://github.com/kanoon201/Satellite-Land-Use

ตารางที่ 8 การแบ่งงาน

สมาชิก	งานที่รับผิดชอบ
ณัฏฐนนท์ รักพานิชมณี	ดึงภาพ Sentinel-2 และ WorldCover จาก Google Earth Engine, เตรียม EuroSAT, ตัด patch และกรองด้วย purity, ตรวจความน่าเชื่อถือของ label และชุดทดสอบ, วิเคราะห์ข้อผิดพลาด, fine-tuning, รายงานและสไลด์
นพรุจ กาศอุดม	ชุดทดสอบที่ตรวจด้วยตา (เครื่องมือ label และรวมผลโหวต), การสำรวจข้อมูล: histogram ของแต่ละ band, NDVI แยกตามคลาส, ขนาด domain shift ต่อ band, จำนวน patch ต่อคลาส และ spectral signature
ณัฐดนัย ผ่องเพ็ญศรี	Random Forest baseline, ResNet-18 สำหรับภาพ 12 band, ทดสอบบน EuroSAT และภาพไทย L1C / L2A, Thai normalisation และ AdaBN, คำนวณคะแนน ผลรายคลาส confusion matrix และตารางเปรียบเทียบทุกการทดลอง